دانشگاه مازندران
دانشکده مهندسی کامپیوتر

گزارش پایانی پروژه درس مباحث ویژه

موضوع پروژه:
طبقه بندی کاندیداهای ریاست جمهوری ایالات متحده به روش نیمه نظارتی

دانشجویان:
سینا نقدی
ارمین پورحمزه

استاد مربوطه:
دکتر میثم روستایی

تیر ۱۴۰۵

۲. چکیده

تحلیل سخنرانی‌های سیاسی و انتساب خودکار آن‌ها به کاندیداها یکی از چالش‌های جذاب و کاربردی در حوزه پردازش زبان طبیعی (NLP) است. در این پروژه، به پیاده‌سازی یک سیستم طبقه‌بندی متون نیمه نظارتی برای تشخیص کاندیداهای ریاست جمهوری ایالات متحده (۱۹ کاندیدا از انتخابات ۲۰۰۸ و ۲۰۱۲) بر اساس گزیده سخنرانی‌های کوتاه (حداکثر ۱۴۰ کاراکتر) پرداخته شده است. چالش اصلی این مجموعه داده، محدودیت شدید داده‌های برچسب‌دار (۱۸۵۳ نمونه آموزشی و ۱۵۸ نمونه ارزیابی) در مقابل حجم بالای داده‌های بدون برچسب (۶۳۶۱ نمونه) است. در این راستا، ابتدا یک مدل نظارتی پایه با استفاده از رگرسیون لجستیک (Logistic Regression) و ویژگی‌های TF-IDF با ترکیب ان-گرام‌ها (Bigrams) پیاده‌سازی شد. سپس از الگوریتم یادگیری نیمه نظارتی خودآموزی (Self-Training) با آستانه اطمینان ۰,۸۵ برای بهره‌برداری از داده‌های بدون برچسب استفاده گردید. نتایج نشان داد که مدل به دقت ۳۲,۹۱٪ روی داده‌های ارزیابی دست یافت. با این حال، تحلیل‌ها نشان داد که افزودن داده‌های بدون برچسب با تکنیک Self-Training سنتی به دلیل پدیده رانش معنایی (Semantic Drift) و ورود نویز برچسب‌های کاذب، بهبود بیشتری در دقت مدل ایجاد نکرده و دقت در سطوح بالاتر داده‌های بدون برچسب به ۳۰,۳۸٪ متمایل شد. این گزارش به بررسی دقیق پیش‌پردازش، استخراج ویژگی، فرآیند آموزش، تحلیل خطاها و ماتریس اغتشاش مدل پرداخته است.

۳. فهرست مطالب

۱. صفحه عنوان ۱
۲. چکیده ۲
۳. فهرست مطالب ۳
۴. مقدمه ۴
۵. توصیف مجموعه داده ۵
۶. روش‌شناسی ۶ ..... (Methodology)
۶,۱ پیش‌پردازش داده‌ها ۶
۶,۲ استخراج ویژگی ۷ ..... (Feature Extraction)
۶,۳ یادگیری نظارتی ۷ ..... (Supervised Learning)
۶,۴ یادگیری نیمه نظارتی ۸ ..... (Semi-Supervised Learning)
۷. نتایج و ارزیابی ۹ ..... (Results)
۷,۱ مقایسه مدل‌ها ۹
۷,۲ ماتریس‌های اغتشاش ۹
۷,۳ تحلیل ویژگی‌ها ۱۰ ..... (Feature Analysis)
۷,۴ تحلیل خطاها ۱۱ ..... (Error Analysis)
۸. بحث و بررسی ۱۲ ..... (Discussion)
۹. نتیجه‌گیری و کارهای آینده ۱۳
۱۰. مراجع ۱۴

۴. مقدمه

تحلیل متون سیاسی به عنوان یکی از شاخه‌های پرکاربرد در علوم داده و پردازش زبان طبیعی، نقش مهمی در درک الگوهای رفتاری، استراتژی‌های تبلیغاتی و جهت‌گیری‌های ایدئولوژیک کاندیداها ایفا می‌کند. با گسترش پلتفرم‌های اجتماعی و رسانه‌های دیجیتال، سخنرانی‌ها و جملات کاندیداها به قطعات کوتاهی تبدیل شده‌اند که تحلیل آن‌ها نیازمند الگوهای پیشرفته یادگیری ماشین است.

هدف اصلی این پروژه، طراحی و پیاده‌سازی یک سیستم هوشمند برای طبقه‌بندی متون کوتاه سخنرانی‌های مربوط به ۱۹ کاندیدای انتخابات ریاست جمهوری ایالات متحده در سال‌های ۲۰۰۸ و ۲۰۱۱۲ است. این مسئله با چالش‌های متعددی روبروست: اولاً، طول متون بسیار کوتاه است (حداکثر ۱۴۰ کاراکتر) که باعث محدودیت اطلاعات بافتی می‌شود. ثانیاً، کاندیداهای هم‌حزبی از ادبیات، واژگان و شعارهای بسیار مشابهی استفاده می‌کنند که مرز بین کلاس‌ها را کمرنگ می‌کند. سوماً، هزینه برچسب‌گذاری متون سیاسی بسیار بالا بوده و در نتیجه داده‌های برچسب‌دار بسیار محدود هستند، در حالی که حجم عظیمی از داده‌های بدون برچسب در دسترس است.

برای حل این چالش، رویکرد یادگیری نیمه نظارتی (Semi-Supervised Learning) به عنوان یک راهکار بهینه بررسی شده است. در این گزارش، ما ابتدا یک مبنای نظارتی قوی با رگرسیون لجستیک ایجاد کرده و سپس تأثیر الگوریتم خودآموزی (Self-Training) را بر بهبود کارایی مدل در مواجهه با داده‌های انبوه بدون برچسب تحلیل می‌کنیم.

۵. توصیف مجموعه داده

مجموعه داده مورد استفاده در این پروژه از یک مسابقه پلتفرم Kaggle استخراج شده است. این مجموعه شامل گزیده سخنرانی‌های کوتاه ۱۹ کاندیدای مطرح (نظیر اوباما، کلینتون، مک‌کین، رامنی و غیره) است. مشخصات آماری این داده‌ها به شرح زیر است:

- تعداد کل نمونه‌های آموزشی برچسب‌دار بارگذاری شده: ۱۸۵۳ نمونه
- تعداد کل نمونه‌های ارزیابی (Dev): ۱۵۸ نمونه
- تعداد نمونه‌های بدون برچسب (Unlabeled): ۶۳۶۱ نمونه
- ساختار متن: فایل‌های متنی کوتاه با طول حداکثر ۱۴۰ کاراکتر

لیست کاندیداهای کلیدی و توزیع پیش‌بینی‌ها روی داده‌های آزمایشی نشان‌دهنده تنوع بالای کلاس‌ها است. برای مثال کاندیداهایی مانند CLINTON_PRIMARY۲۰۰۸ و OBAMA_PRIMARY۲۰۰۸ بیشترین سهم را در مجموعه داده دارند که این امر موجب عدم توازن (Imbalance) شدید در کلاس‌ها شده است.

۶. روش‌شناسی (Methodology)

۶,۱ پیش‌پردازش داده‌ها

با توجه به ماهیت نویزدار متون کوتاه سیاسی، مراحل پیش‌پرازیش زیر به صورت دقیق بر روی تمامی متون اعمال شد:

۱. تبدیل به حروف کوچک (Lowercase Conversion): برای یکسان‌سازی کلمات (مانند تبدیل President و president به یک شکل).

۲. حذف علائم نگارشی (Punctuation Removal): حذف علائمی مانند نقطه، کاما، علامت سوال که ارزش معنایی برای طبقه‌بندی ندارند.

۳. نرمال‌سازی فضاهای خالی (Whitespace Normalization): حذف فضاهای خالی اضافی و تبدیل متن به یک ساختار یکدست.

۴. حذف کلمات توقف (Stop Words Removal): کلمات پر تکرار مانند 'the', 'is', 'at' که در تمامی متون مشترک هستند حذف شدند تا تمرکز مدل بر کلمات کلیدی قرار گیرد.

۶,۲ استخراج ویژگی (Feature Extraction)

برای تبدیل متن به بردار عددی قابل فهم برای مدل، از روش TF-IDF (Term Frequency-Inverse Document Frequency) استفاده شد. پارامترهای تنظیم شده عبارتند از:

- max_features=۱۵۰۰۰: انتخاب ۱۵،۰۰۰ ویژگی برتر بر اساس فرکانس.
- ngram_range=(۱،۲): استفاده ترکیبی از تک کلمه‌ها (Unigrams) و جفت کلمه‌ها (Bigrams).

استفاده از Bigrams در متون سیاسی بسیار حیاتی است؛ زیرا عباراتی مانند 'secret prisons' یا 'democratic reform' معنای کاملاً متفاوتی نسبت به کلمات مجزای خود دارند و بازتاب‌دهنده دقیق‌تر تفکرات یک کاندیدا هستند.

۶,۳ یادگیری نظارتی (Supervised Learning)

الگوریتم رگرسیون لجستیک (Logistic Regression) به عنوان مدل نظارتی مبنا انتخاب شد. دلیل این انتخاب، کارایی بسیار بالا و سرعت فوق‌العاده این مدل در فضاهای ویژگی با ابعاد بالا (مانند متون TF-IDF) و همچنین تفسیرپذیری بالای ضرایب آن

است. برای مقابله با عدم توازن کلاس‌ها، از پارامتر 'class_weight='balanced استفاده شد و بهینه سازی ابرپارامتر C با کمک GridSearchCV انجام گرفت.

۶,۴ یادگیری نیمه نظارتی (Semi-Supervised Learning)

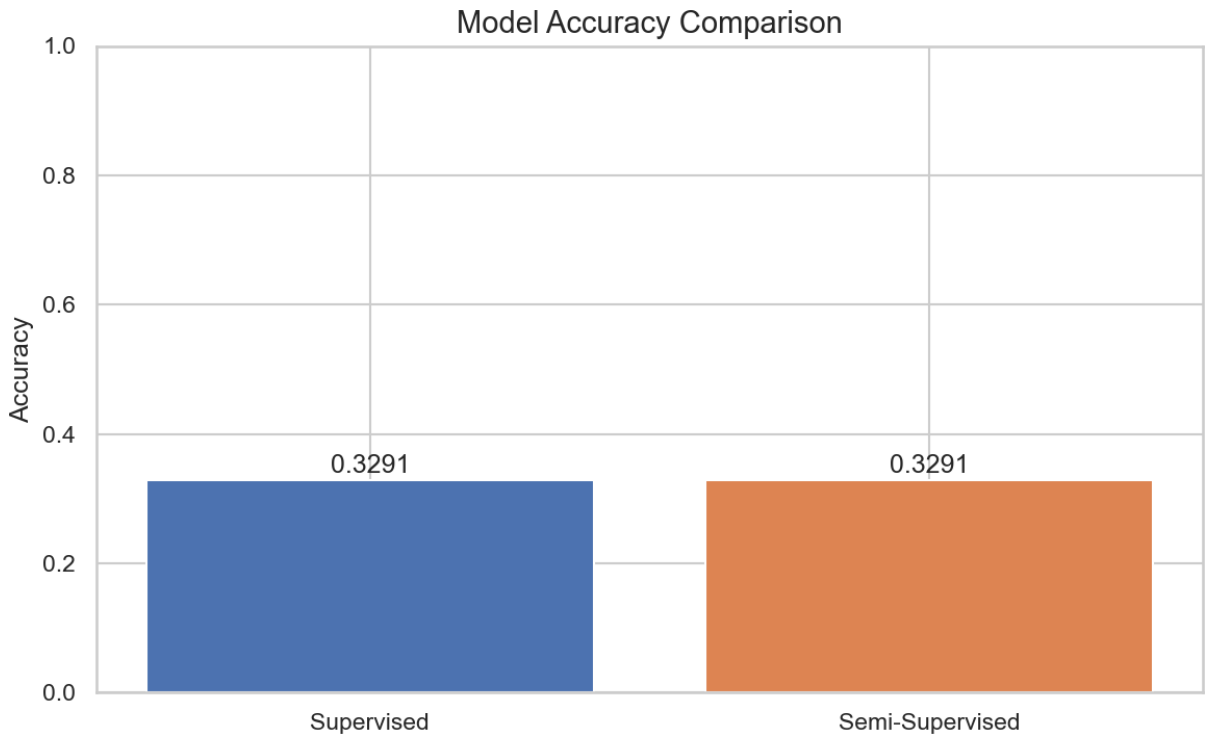
الگوریتم خودآموزی (Self-Training) برای بهره‌گیری از داده‌های بدون برچسب پیاده‌سازی شد. فرآیند گام به گام آن به این صورت است که ابتدا مدل روی داده‌های برچسب‌دار آموزش می‌بیند، سپس پیش‌بینی‌های خود را روی داده‌های بدون برچسب انجام می‌دهد. نمونه‌هایی که احتمال پیش‌بینی آن‌ها بالاتر از آستانه اطمینان (Confidence Threshold = ۰,۸۵) باشد، همراه با برچسب‌های شبه واقعی (Pseudo-Labels) به مجموعه آموزش اضافه می‌شوند و مدل مجدداً بازآموزی می‌شود.

۷. نتایج و ارزیابی (Results)

۷٫۱ مقایسه مدل‌ها

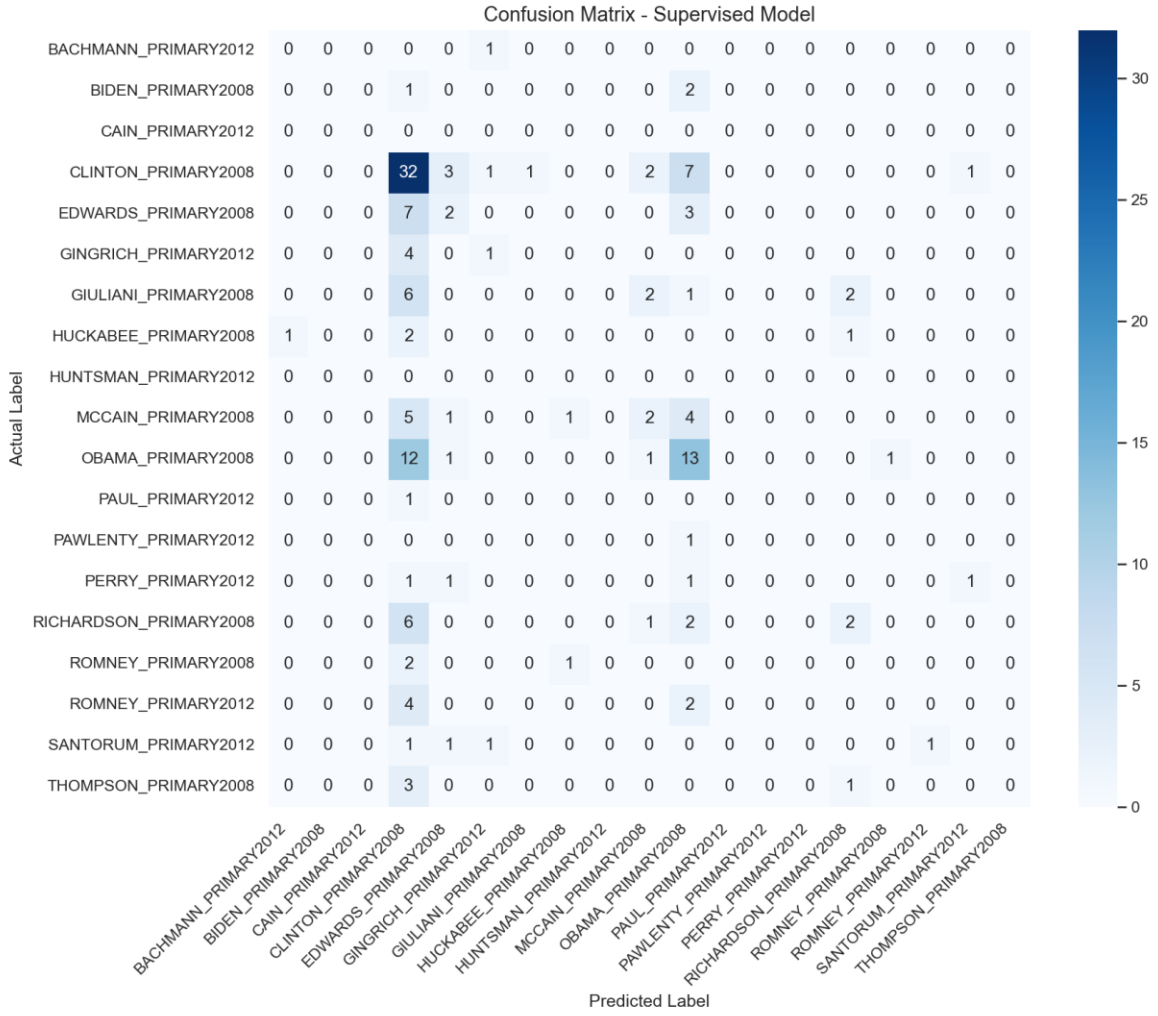
جدول زیر عملکرد مدل را در میزان استفاده از داده‌های بدون برچسب نشان می‌دهد:

درصد داده‌های بدون برچسب استفاده شده	دقت مدل روی داده‌های ارزیابی (Dev Set)
۰٪	۰.۳۲۹۱ (۳۲.۹۱٪)
۲۵٪	۰.۳۰۳۸ (۳۰.۳۸٪)
۵۰٪	۰.۳۰۳۸ (۳۰.۳۸٪)
۷۵٪	۰.۳۰۳۸ (۳۰.۳۸٪)
۱۰۰٪	۰.۳۰۳۸ (۳۰.۳۸٪)

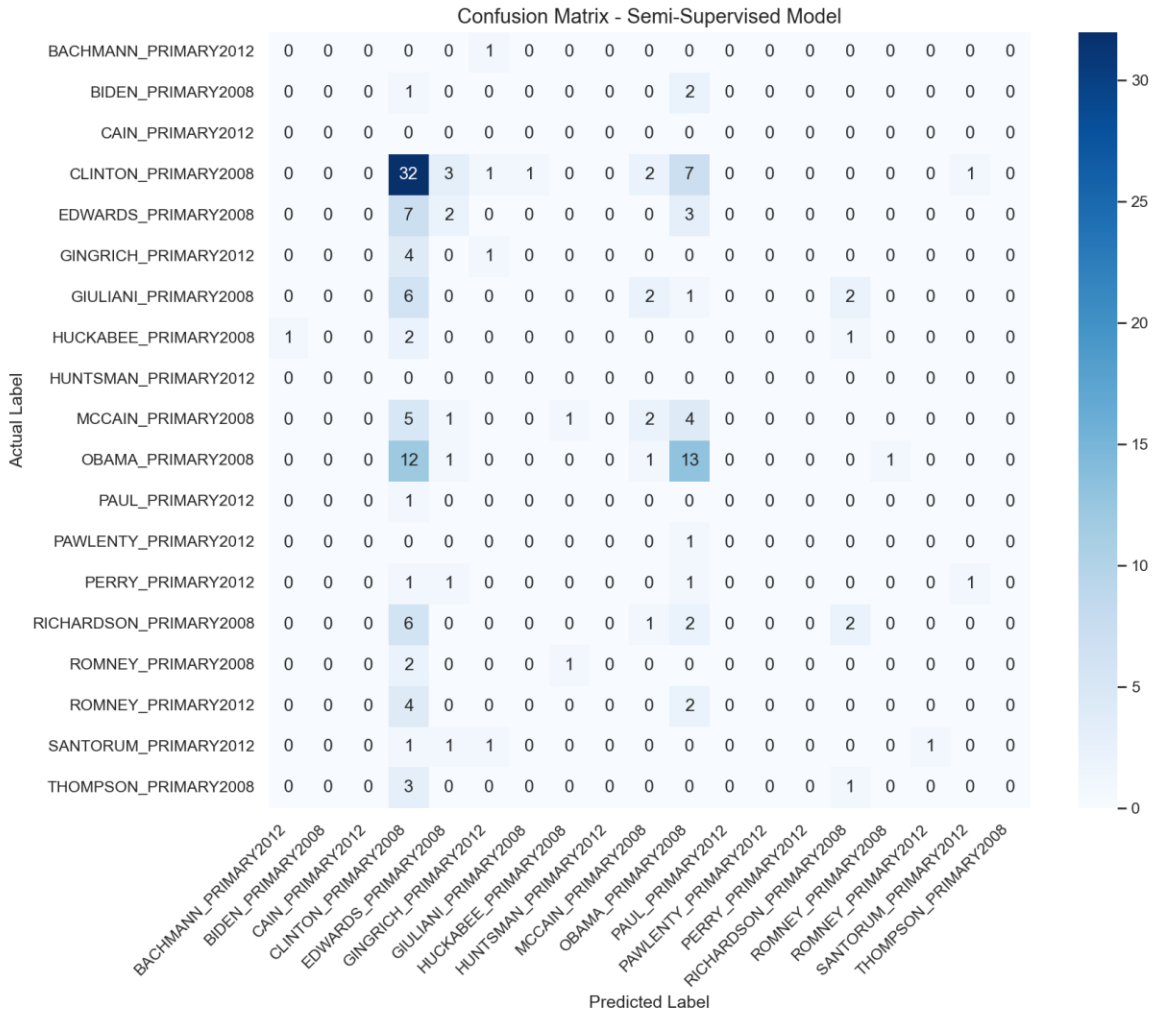


توضیح تصویر: نمودار فوق تاثیر افزودن درصدهای مختلف داده‌های بدون برچسب را بر روی دقت مدل نشان می‌دهد.

۷,۲ ماتریس‌های اغتشاش



توضیح تصویر: ماتریس اغتشاش مدل نظارتی پایه.



توضیح تصویر: ماتریس اغتشاش مدل نیمه نظارتی پس از اعمال الگوریتم Self-Training.

۷٫۳ تحلیل ویژگی‌ها (Feature Analysis)

تحلیل کلمات کلیدی مثبت و منفی برای برخی کاندیداهای شاخص نشان‌دهنده الگوهای زبانی جالب توجهی است:

• کاندیدا BACHMANN_PRIMARY۲۰۱۲:

- ویژگی‌های مثبت برتر: team, israel, millions jews, stop, iowa, constitution stop

- ویژگی‌های منفی برتر: know, new, need, just, time, care

• کاندیدا BIDEN_PRIMARY۲۰۰۸:

- ویژگی‌های مثبت برتر: plan, sectarian, leave, troops, democratic reform, secret prisons

- ویژگی‌های منفی برتر: people, america, new, country, think

• کاندیدا ۲۰۱۲CAIN_PRIMARY:

- ویژگی‌های مثبت برتر: new vision, god journey, god, decision run, frustration, distractions false

- ویژگی‌های منفی برتر: president, know, need, going, work

۷,۴ تحلیل خطاها (Error Analysis)

تعداد کل خطاهای مدل روی مجموعه ارزیابی ۱۰۶ خطا از ۱۵۸ نمونه بوده است که معادل نرخ خطای ۶۷,۰۹٪ می‌باشد. ۵ مورد از رایج‌ترین اشتباهات مدل به شرح زیر است:

۱. اشتباه گرفتن اوباما با کلینتون (OBAMA -> CLINTON): دوازده مورد

۲. اشتباه گرفتن کلینتون با اوباما (CLINTON -> OBAMA): هفت مورد

۳. اشتباه گرفتن ادواردز با کلینتون (EDWARDS -> CLINTON): هفت مورد

۴. اشتباه گرفتن ریچاردسون با کلینتون (RICHARDSON -> CLINTON): شش مورد

۵. اشتباه گرفتن جولیانی با کلینتون (GIULIANI -> CLINTON): شش مورد

۸. بحث و بررسی (Discussion)

کاهش عملکرد مدل از ۳۲٫۹۱٪ به ۳۰٫۳۸٪ پس از ورود داده‌های بدون برچسب، نشان‌دهنده چالش‌های کلاسیک در یادگیری نیمه نظارتی است. هنگامی که آستانه اطمینان بالا (۰٫۸۵) در نظر گرفته می‌شود، مدل تنها نمونه‌هایی را برچسب‌گذاری می‌کند که به کلاس‌های غالب (مانند کلینتون یا اوباما) تمایل دارند. این فرآیند باعث تقویت سوگیری (Bias) مدل به سمت کلاس‌های پرتکرار شده و نویز برچسب‌گذاری را افزایش می‌دهد که اصطلاحاً به آن ریسک انتشار خطا (Error Propagation) می‌گویند.

توزیع نهایی پیش‌بینی‌ها روی داده‌های تست مسابقه Kaggle به خوبی این پدیده را تایید می‌کند؛ از میان ۶۳۶۱ پیش‌بینی انجام شده، ۲۹۵۱ مورد به CLINTON_PRIMARY۲۰۰۸ و ۱۳۶۷ مورد به OBAMA_PRIMARY۲۰۰۸ اختصاص یافته است، در حالی که کاندیداهایی مانند کین (CAIN) تنها ۷ پیش‌بینی دریافت کرده‌اند.

۹. نتیجه‌گیری و کارهای آینده

در این پروژه، یک سیستم طبقه‌بندی متون سیاسی نیمه نظارتی طراحی و پیاده‌سازی شد. اگرچه رگرسیون لجستیک ترکیب شده با TF-IDF سرعت بالایی دارد، اما به دلیل محدودیت متون کوتاه در استخراج روابط معنایی عمیق، با نرخ خطای بالایی روبرو شد. برای کارهای آینده، پیشنهاد می‌شود از مدل‌های پیشرفته‌تر تبدیل‌کنندگان زبانی مانند BERT یا RoBERTa به همراه روش‌های نیمه نظارتی مدرن‌تر مانند Co-Training یا متدهای مبتنی بر Consistency Regularization استفاده شود تا بازنمایی‌های معنایی غنی‌تری حاصل گردد.

۱۰. مراجع (References)

۱. Yarowsky, D. (۱۹۹۵), Unsupervised word sense disambiguation rivaling supervised methods. In Proceedings of the ۳۳rd annual meeting on Association for Computational Linguistics.

۲. Zhu, X. (۲۰۰۵), Semi-supervised learning literature survey. Computer Sciences, University of Wisconsin-Madison.

۳. Joachims, T. (۱۹۹۸), Text categorization with support vector machines: Learning with many relevant features. European conference on machine learning.

۴. McCallum, A., & Nigam, K. (۱۹۹۸), A comparison of event models for naive bayes text classification. AAAI-۹۸ workshop on learning for text categorization.

۵. Pedregosa, F., et al. (۲۰۱۱), Scikit-learn: Machine learning in Python. Journal of Machine Learning Research.

۶. Blei, D. M., Ng, A. Y., & Jordan, M. I. (۲۰۰۳), Latent dirichlet allocation. Journal of machine Learning research.

۷. Mikolov, T., et al. (۲۰۱۳), Distributed representations of words and phrases and their compositionality. Advances in neural information processing systems.

۸. Chapelle, O., Scholkopf, B., & Zien, A. (۲۰۰۶), Semi-supervised learning. MIT Press.